

DOCUMENTO DE DEFINICIÓN DE PROCESO (PDD)

BOT HEADHUNTER IT - AUTOMATIZACIÓN DE SCRAPING E IA GENERATIVA

1. Control de Versiones del PDD

Se indica la fecha en la que se realiza una versión del documento, el número de versión, así como la persona que la realiza.

Versión	Fecha	Autor	Observaciones
1.0	17.06.2026	Javier Jaenes Molina	Creación inicial del documento

2. Flujo de Aprobación de Documentos

Se indica la fecha en la que se aprueba y la persona responsable. En caso de no revisarse, cuando se comienza el desarrollo, se envía al cliente indicando en este punto su No revisión.

Versión	Fecha	Persona que Revisa	Observaciones
1.0	17.06.2026	Responsable Técnico / RRHH	Aprobación de alcance y reglas de negocio

3. Introducción

3.1 Propósito

El documento de Definición del Proceso (PDD) describe el proceso de negocio seleccionado para su automatización mediante una arquitectura híbrida (Power Automate Desktop y n8n). En este documento se describe la secuencia de pasos a realizar durante el proceso de dos formas distintas:

- **Análisis Funcional:** Se explica de forma detallada cómo las personas encargadas del proceso lo realizan manualmente. Se valida para asegurar que se ha comprendido a la perfección el proceso que se debe realizar.
- **Análisis Técnico:** Se explica de forma detallada cómo va a realizar el bot el proceso, identificando tareas que el bot puede realizar de forma automática e integrando sistemas externos (Navegación web RPA, API de IA generativa y Base de datos SQL).

3.2 Objetivos

La finalidad de este documento es recoger los siguientes puntos:

- Detalle del paso a paso del proceso manual y automatizado.
- Requisitos para el desarrollo y la ejecución del bot.
- Evaluación de salidas funcionales del bot y reglas de negocio aplicadas (Match Score).
- Plan de contingencia ante posibles fallos de ejecución.

3.3 Alcance del Proyecto

El alcance del proyecto se limita a lo recogido en este documento. El fin del bot es realizar todos y cada uno de los puntos detallados (Extracción en InfoJobs y Tecnoempleo, evaluación por IA, guardado en base de datos y reporte por email). Cualquier modificación, mejora o ampliación del comportamiento del robot se podrá realizar como evolutivo del mismo, tras su correspondiente análisis y cotización.

4. Descripción del Proceso: Análisis Funcional

4.1 Descripción General del Proceso

El proceso consiste en la búsqueda recurrente de vacantes de desarrollo de software multiplataforma, la criba inicial descartando roles no deseados, la evaluación de la descripción de la vacante frente a las habilidades del candidato y la centralización de los resultados en un boletín resumen enviado por correo.

4.2 Aplicaciones Utilizadas

Se detallan todos los aplicativos necesarios para realizar el proceso:

Aplicación	Versión	Perfil	Ubicación	Función
Power Automate Desktop	N/A	Ejecutor RPA	Entorno Local	Extracción web
Microsoft Edge	N/A	Interfaz	Entorno Local	Navegación
n8n	1.x / 2.x	Orquestador	Nube	Lógica de enrutamiento
Groq	gpt-oss-20b	API	Nube	Agente Evaluador LLM
Supabase (PostgreSQL)	N/A	Base de datos	Nube	Almacenamiento

Aplicación	Versión	Perfil	Ubicación	Función
Google Sheets	N/A	Configuración	Nube	Lista de Keywords

4.3 Entrada al Proceso

Requisitos previos necesarios para que el proceso pueda realizarse:

- El archivo de Excel/Sheets KeywordsTemporales.xlsx debe contener en su primera columna los términos de búsqueda (ej. "Java", "C#", "Python", "RPA").
- El equipo local debe estar encendido a la hora programada por el Programador de Tareas.

4.4 Paso a Paso del Proceso Manual

Proceso actual realizado por un perfil en búsqueda activa:

1. Abre el navegador y entra en los distintos portales de empleo.
2. Introduce cada una de las tecnologías de su stack una por una en el buscador.
3. Lee el título y la descripción de cada oferta.
4. Desarta mentalmente aquellas que exigen 5 años de experiencia, rol "Lead" o "Senior".
5. Compara los requisitos de las restantes con su perfil profesional y guarda los enlaces interesantes.
6. Agrupa las vacantes por orden de prioridad para postularse a lo largo de la mañana.

4.5 Descripción de Datos de Salida

El proceso finaliza con los siguientes elementos:

- Nuevos registros limpios y puntuados almacenados en la tabla ofertas_infojobs.

- Un correo electrónico en formato HTML en la bandeja de entrada del usuario con un reporte clasificado en tres niveles de prioridad (Alta, Media, Baja).

5. Descripción del Proceso: Análisis Técnico

5.1 Arquitectura General del Bot

El bot implementa una arquitectura desacoplada en dos flujos temporales:

- **Flujo de Ingesta (Continuo):** Un script de RPA extrae datos brutos de la web y los inyecta en el orquestador n8n, donde la IA los clasifica y la base de datos los almacena.
- **Flujo de Notificación (Programado):** Un *Schedule Trigger* en n8n recupera las ofertas de las últimas 24 horas y emite el resumen por SMTP.

5.2 Paso a Paso Técnico

1. **Inicialización (Local):** El robot lee la hoja de cálculo y almacena las Keywords en la variable ListaBusquedas.
2. **Navegación (RPA):** Inicia Microsoft Edge. Un bucle itera sobre la lista de palabras realizando búsquedas en InfoJobs y Tecnoempleo.
3. **Extracción y Envío:** Captura el Título, Empresa y Enlace (atributo href). Empaqueta los datos en formato JSON y realiza una petición HTTP POST al Webhook de n8n.
4. **Filtro de Negocio (n8n):** Un nodo If comprueba si el título contiene "senior", "lead", "5 años" o "ingeniero". Si es True, la oferta se descarta.
5. **Agente de IA (n8n):** El nodo de Groq recibe la oferta con el System Prompt del Headhunter. Devuelve un JSON estructurado con el match_score y el motivo justificado.
6. **Upsert en Base de Datos:** n8n formatea los datos e inserta la oferta en Supabase. Si la URL ya existe, la ignora para evitar duplicados.

7. **Emisión de Reporte:** A las 09:00 AM, el segundo flujo de n8n consulta la base de datos, un script JS maqueta el HTML condicionalmente y el nodo Send Email distribuye el boletín final.

5.3 Manejo de Errores y Reintentos

El bot implementa resiliencia mediante:

- Bloques ON ERROR en Power Automate Desktop en las interacciones de UI complejas, impidiendo que el robot local se cuelgue ante modales o ventanas emergentes.
- Gestión dinámica de las tablas web adaptándose a la estructura del DOM de distintos portales.
- Borrado automatizado de base de datos a través de una función pg_cron programada en el backend SQL.

6. Gestión de Excepciones

6.1 Excepciones de Negocio (Business Exception)

Excepciones conocidas que se detectan durante el análisis. Se controlan explícitamente:

Código	Descripción	Acción a Realizar
BE-01	Perfil sobrecualificado	El nodo Switch (If) de n8n detecta términos excluyentes en el título y detiene la rama, ahorrando consumo de IA.
BE-02	Oferta duplicada	La acción UPSERT en la base de datos detecta el identificador único (enlace) y descarta la escritura de la fila repetida.
BE-03	Score por debajo del 50%	El script de reporte categoriza la oferta en "Revisión Secundaria", separándola del foco principal visual.

6.2 Excepciones Técnicas (System Exception)

Excepciones no controladas que se producen de forma impredecible:

Código	Descripción	Acción a Realizar
SE-01	Modificación del HTML	PAD captura la excepción mediante el bloque ON ERROR, abandona esa iteración web y continúa con el siguiente portal de la lista.
SE-02	Timeout de IA (Groq)	El sistema orquestador deberá ejecutar reintentos automáticos a nivel de nodo para asegurar la ingesta del payload.

7. Notificaciones e Informes

7.1 Alertas de Error

En caso de un volcado masivo erróneo o error de conexión con la IA, el flujo contempla derivaciones o logs visuales en la consola local del sistema.

7.2 Informes de Éxito

El proceso culmina con un reporte consolidado categorizado:

-  **Imprescindibles (Match $\geq$ 80%)**
-  **Posiciones de Interés (50% - 79%)**
-  **Revisión Secundaria (< 50%)**

8. Plan de Contingencia y Riesgos

8.1 Matriz de Riesgos

Riesgo	Probabilidad	Impacto	Mitigación
Caída del Webhook local (ngrok)	Alta	Alto	Utilizar IPs fijas o Cloudflare Tunnels para asegurar el <i>endpoint</i> de comunicación.
Desbordamiento de Memoria (RAM)	Alta	Alto	Cierre sistemático de las instancias de navegador Edge desde PAD.
Exceso de almacenamiento DB	Baja	Medio	CRON interno en PostgreSQL borrando filas con más de 30 días de antigüedad.

8.2 Procedimiento de Rollback

En caso de fallo crítico del bot de orquestación en la nube:

- El scraping continúa siendo posible de forma manual entrando a los portales correspondientes.
- El histórico de la base de datos de Supabase permanece intacto para poder consultar la actividad de semanas previas, manteniendo el progreso almacenado de forma segura en la nube.

9. Conclusión

Este documento describe la automatización integral de captación de oportunidades IT mediante un sistema que:

- Integra RPA para salvar barreras anti-scraping simulando navegación humana.
- Aplica inteligencia artificial para calificar la información no estructurada de forma inteligente.
- Elimina completamente el "ruido" de falsos positivos en las bolsas de empleo.
- Mantiene una infraestructura escalable en la nube (n8n + PostgreSQL).

El alcance se limita exclusivamente a los puntos detallados en este documento.

Dev. Javier Jaenes Molina / Junio 2026

Javier Jaenes Molina | LinkedIn